

# Reinforcement Learning pro ovládání robotů

Bc. Tomáš Bijeczek

Vedoucí práce: prof. Ing. Jan Platoš, Ph.D.

# Cíl práce

- Navrhnout a otestovat metody učení robotů pomocí metod reinforcement learningu ve vybraném simulačním prostředí
- Naučit šestinožého robota pohybovat se k cíli na různých typech terénu

# Motivace

- Otestovat metody reinforcement learningu na méně obvyklém typu robota
- Osobní zájem zjistit možnosti tohoto přístupu

# Reinforcement learning

- Metoda strojového učení inspirovaná procesem učení u lidí a zvířat
- Agent vykonává akce, na ty dostává od prostředí příslušnou zpětnou vazbu
- Cílem je naučit se chování, které maximalizuje kumulativní odměnu v průběhu času

# Využití RL v robotice

- Eliminace manuálního naprogramování požadovaného chování
- Šance osvojení efektivnějšího chování, které by jinak nebylo zřejmé
- Nutnost použití vhodného algoritmu a věrohodného simulačního prostředí

# Dostupné simulátory


- NVIDIA Isaac Lab – HW požadavky
- Gymnasium – chybějící editor scén společně s absencí složitějších fyzikálních simulátorů
- Coppeliasim – editor scény, integrovaný fyzikální engine, předvytvořené 3D modely

# PyRep

- Knihovna, umožňující propojení CoppeliaSim scény s Python prostředím
- Hlavní funkce:
  - Načtení scény
  - Spuštění simulace
  - Pozastavení simulace
  - Provedení simulačního kroku
  - Ukončení simulace
- Umožňuje ovládání robotů, získávání dat ze senzorů či jiných objektů scény







# Hexapod

- Mobilní robot, 6 nohou, 18 rotačních kloubů
- Akční prostor obsahuje pozice těchto kloubů
- Stavový prostor obsahuje informace o aktuálním stavu robota v prostředí





# Hexapod – omezení pohybu


- Rozsah rotace prvního kloubu -90 až 90 stupňů
- Rozsah rotace druhého kloubu -90 až 120 stupňů
- Rozsah rotace třetího kloubu -80 až 175 stupňů



# Scéna prvního experimentu



# Scéna druhého a třetího experimentu



# Pozorovací prostor


- Normalizovaný směr robota k cíli (3 hodnoty).
- Normálový vektor terénu pod aktuální pozicí robotova těla (3 hodnota).
- Pozice kloubů (18 hodnot).
- Rychlost pohybu kloubů (18 hodnot).
- Orientace robota (6 hodnot).
- Lineární rychlost robotova těla (3 hodnoty).
- Úhlová rychlost robotova těla (3 hodnoty).
- Vzdálenost robotova těla od země (1 hodnota).
- Vzdálenost koncových částí končetin od země (6 hodnot).
- Lineární rychlosti koncových částí končetin (6 hodnot)

## TD3


- Algoritmus z kategorie hlubokého reinforcement learningu
- Spojitý akční prostor
- Hlavní vlastnosti:
  - Off-Policy
  - Aktér-Kritik architektura sítí (1 aktér, 2 kritici)
  - Replay buffer
  - Explorační a target policy šum
  - Soft update – target síť
  - Opožděná aktualizace aktérový sítě
  - Velká citlivost na hyperparametry

# Architektura sítí TD3

Aktér



Kritik



# Způsob tréninku sítí

- Paralelní sběr zkušeností, které se zasílají učiteli
- Komunikace pomocí fronty zpráv
- Učitel je zodpovědný za trénink sítí, které periodicky zasílá všem pracovníkům

# Hlavní simulační smyčka - ukázka jedné epizody

- Epizoda je ukončena při dosažení cíle nebo při převrácení robota

---

**Algoritmus 3** Metoda `run_episode()` - Logika simulační smyčky jednotlivých kroků dané epizody

---

**Input:** Maximální počet kroků

**Output:** Celková odměna epizody, příznak dosažení cíle, kroky epizody, komponenty odměny

```
1: získej stav = zavolej metodu reset()
2: Uveď šum do výchozího stavu
3: Pokud učitel zaslal novou konfiguraci vah, aktualizuj aktérovu síť
4: nastav kroky = 0, celkova_odmena = 0
5: while kroky < maximální počet kroků do
6:     nastav akce = výstup aktérové sítě pro [stav] a přidej k nim šum
7:     Nastav cílové pozice akcí kloubů robota
8:     while neplatí all_joints_reached_targets() do
9:         Proved simulační krok
10:    end while
11:    následující stav, odměna, příznak ukončení epizody, příznak dosažení cíle = zís-
    kej zpětnou vazbu prostředí za provedení akce v daném stavu
12:    Zašli stav, akce, odměna, následující stav a příznak ukončení epizody učiteli
13:    kroky += 1
14:    celkova_odmena += odměna
15:    if příznak ukončení epizody nebo příznak dosažení cíle then
16:        break
17:    end if
18:    nastav stav = následující stav
19: end while
20: return celkova_odmena, příznak dosažení cíle, kroky, komponenty odměny
```

---

$$\text{stability\_reward} = 0.4 \cdot \text{body\_tilt\_reward} + 0.6 \cdot \text{body\_height\_reward}$$

# Odměnová funkce

$$\text{legs\_reward} = 0.05 \cdot \text{tip\_reward} + 0.95 \cdot \text{tilt\_reward}$$

$$\text{motion\_reward} = 1.0 \cdot \text{velocity\_reward}$$

- Odměna za výšku a náklon těla
- Odměna za náklon a vzdálenost koncových částí končetin od terénu
- Odměna za pohyb směrem k cíli
- Penalizace za převrácení

$$\text{reward} = \text{stability\_reward} + \text{legs\_reward} + 2 * \text{motion\_reward} + \text{fell\_over\_reward}$$

# Obecné nastavení experimentů

| Parametr                                | Hodnota     |
|-----------------------------------------|-------------|
| Maximální počet epizod                  | 40000       |
| Maximální počet kroků v epizodě         | 150         |
| Učící konstanta aktéra                  | 0,0001      |
| Optimalizační algoritmus aktéra         | Adam        |
| Učící konstanta kritika                 | 0.001       |
| Optimalizační algoritmus kritika        | Adam        |
| Velikost paměti zkušeností              | 1000000     |
| Počet kroků zahřívací fáze              | 500         |
| Velikost dávky                          | 256         |
| Diskontní faktor $\gamma$               | 0,99        |
| Faktor aktualizace cílových sítí $\tau$ | 0,005       |
| Frekvence aktualizace sítí              | 100         |
| Počáteční a konečné nastavení šumu      | 0,2 ; 0,005 |
| Kroky úbytku šumu                       | 75000       |


|                |                     |
|----------------|---------------------|
| OS             | Ubuntu-20.04 (WSL2) |
| Procesor       | AMD Ryzen 5 5600H   |
| Grafická karta | RTX 3060 Laptop     |
| RAM            | 16GB                |

Tabulka 5.2: Specifikace PC


# První experiment

- Cíl: naučit hexapoda pohybu k cíli na rovném terénu
- Výsledky experimentu vedly k úpravě velikosti aktérové sítě i samotné struktury pozorovacího prostoru (vektor terénu, rychlost koncových částí končetin)

| Parametr                           | Hodnota               |
|------------------------------------|-----------------------|
| Název scény                        | scene_experiment1.ttt |
| Doba tréninku                      | 14h 2min              |
| Dosažený počet epizod              | 6600                  |
| Velikost paměti zkušeností         | 50000                 |
| Počet hodnot pozorovacího prostoru | 59                    |



Obrázek 5.1: Průběžná odměna v průběhu prvního experimentu




Obrázek 5.2: Průměrná odměna za krok v průběhu prvního experimentu

- Odkaz: [Diplomová práce - hexapod první experiment - YouTube](#)

## Druhý experiment

- Cíl: naučit hexapoda pohybu k cíli na hornatém terénu
- Oproti prvnímu experimentu vytvořeny zachytné body – korektní směr k cíli na hornatém terénu

| Parametr              | Hodnota               |
|-----------------------|-----------------------|
| Název scény           | scene_experiment2.ttt |
| Doba tréninku         | 11h 39min             |
| Dosažený počet epizod | 5000                  |



Obrázek 5.5: Průběžná odměna v průběhu druhého experimentu



Obrázek 5.6: Průměrná odměna za krok v průběhu druhého experimentu

- Odkaz: [Diplomová práce - hexapod druhý experiment - YouTube](#)

# Závěr

- Šestinohý robot se díky algoritmu TD3, CoppeliaSim a PyRep naučil pohybovat k cíli na různých typech terénu
- Problém s časem trénování a laděním hyperparametrů – časově nákladné
- Rozšíření: Na tělo šestinohého lze umístit kameru, díky níž by byl schopen rozpoznávat objekty a případně se vyhýbal různým typům překážek

# Otázky k obhajobě

- Dá se popsany koncept použít pro více robotů v jednom prostředí? Jak byste model rozšířil pro interakci více robotů?

**Děkuji za pozornost**